




Evaluación 1 – Calidad y Preparación de Datos

Análisis del rendimiento académico

Nombre: Constanza Tapia Campos
Maura González González
Felipe Riquelme Suárez
Samuel Loyola Jara
Profesora: Jazna Meza Hidalgo.
Fecha: 04-09-2026

Dataset y objetivo del analisis


Carcateristicas	Resultado
Registros iniciales	5.100
Variables	11
Variables numericas predictoras	7
Variables categoricas predictoras	2
Identificador	StudentID
Variable Objetivo	FinalGrade

Objetivo: diagnosticar la calidad de los datos, explorar el rendimiento académico y construir un proceso reproducible de preparación de datos.




Diagnóstico inicial de calidad

Problema	Resultado
Valores Faltantes	1335
Duplicados exactos	100
Inconsistencias de dominio	63
Inconsistencias categoricas	71
Outliers IQR	393



Principales inconsistencias encontradas




Variable	Problema	Evidencia/Ejemplo
Attendance	Fuera de rango	20 casos; valores $< 0\%$ o $> 100\%$
SleepHours	Valores imposibles	8 casos; horas negativas
InternetHours	Fuera de dominio	31 casos; hasta 69,5 h/día
FinalGrade	Nota inválida	4 casos con valores < 1
Scholarship	Categorías duplicadas	35 casos; Sí, si, SI, NO, espacios
Program	Escritura inconsistente	36 casos; diferencias de mayúsculas, tildes y escritura

Resultados Principales del EDA

Se observa una asociación positiva con FinalGrade, especialmente según Spearman ($\rho \approx 0,71$).


StudyHours vs FinalGrade



Resultados Principales del EDA

Los estudiantes con beca presentan un promedio de 4,37 frente a 4,07 sin beca


Scholarship vs Finalgrade



Resultados Principales del EDA


La asistencia presenta una asociación positiva con FinalGrade ($p \approx 0,63$, $r \approx 0,59$).

Attendance vs Finalgrade



Decisiones de tratamiento

Problema	Tratamiento
Duplicados	Eliminar copias exactas
Números faltantes	Imputar con mediana
Categoricas faltantes	Imputar con moda
Categorías inconsistentes	Normalizar etiquetas
Valores imposibles	Convertir a NaN e imputar
FinalGrade invalido	Eliminar registros
Outliers validos	Conservar



Conclusiones principales del EDA

Hábitos académicos

StudyHours y Attendance mostraron asociaciones positivas con FinalGrade, siendo StudyHours la relación más intensa según Spearman ($p \approx 0,71$).

Programa académico


Ingeniería Informática presentó el mayor promedio de FinalGrade ($\approx 4,23$), mientras que Contador Auditor presentó el menor ($\approx 4,05$). La diferencia entre ambos fue de aproximadamente 0,18 puntos.

Diferencias entre grupos

Los estudiantes con beca presentaron un promedio de 4,37 frente a 4,07 sin beca, observándose una diferencia descriptiva de 0,30 puntos.


Calidad de los datos

La presencia de outliers no implicó automáticamente un error. Se conservaron observaciones extremas válidas y se trataron únicamente los valores incompatibles con el dominio de cada variable.



Resultado final y conclusión

El dataset final quedó sin valores faltantes, sin duplicados y sin inconsistencias detectadas.



Indicador	Original	Tratado
Registros	5100	4996
Variables	11	16
Faltantes	1335	0
Duplicados	100	0
Inconsistencias	134	0